

**Федеральное государственное автономное образовательное
учреждение высшего образования
«Национальный исследовательский университет
«Высшая школа экономики»**

**Факультет Санкт-Петербургская школа физико-математических и
компьютерных наук
Департамент информатики**

**ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА
(БАКАЛАВРСКАЯ РАБОТА)**

на тему

**«Методы оценки сложности текстовых данных для ускорения
обучения языковых моделей с помощью обучения по плану»**

Направление подготовки 01.03.02 Прикладная математика и информатика

Выполнил студент группы БПМ171С, 4 курса,
образовательной программы «Прикладная математика и информатика»
Сурков Максим Константинович

Научный руководитель:
? Ямщиков Иван Павлович

Санкт-Петербург
2021

Оглавление

Аннотация	3
Введение	5
1. Обзор литературы	7
1.1. Возникновение обучения по плану	7
1.2. Применение обучения по плану в смежных сферах машинного обучения	7
1.3. Применение обучения по плану в обработке естественного языка	8
1.4. Существующие метрики оценки сложности текстов	11
1.5. Выводы	12
2. Метрики оценки сложности текстов	13
2.1. Описание метрик	13
2.2. Алгоритмы вычисления метрик	16
2.3. Сбор статистик	18
2.4. Выводы	19
3. Эксперименты	20
3.1. Конфигурация экспериментов	20
3.2. Метод сравнения метрик	20
3.3. Семплы	21
3.4. Влияние обучения по плану на задаче предобучения	22
3.5. Влияние обучения по плану на задаче классификации	24
3.6. Влияние обучения по плану на шумном корпусе данных	26
3.7. Выводы	27
Заключение	28
Список литературы	29

Аннотация

Современные системы обработки естественного языка активно используют глубокие нейронные сети (BERT, GPT-3), которые требуют значительных ресурсов для их обучения. За последние годы было разработано множество подходов для решения данной проблемы. Одним из них является обучение по плану. Данный метод состоит из двух составляющих: оценки сложности тренировочных данных и алгоритма их семплирования. Основной целью данной работы является исследование метрик оценки сложности текстовых данных в контексте обучения по плану и влияния данного метода ускорения обучения на скорость сходимости языковых моделей на задачах предобучения и классификации. В процессе исследований было предложено и адаптировано несколько подходов из разных областей математики. Также были реализованы производительные алгоритмы вычисления найденных метрик на больших объемах данных в несколько десятков миллионов тренировочных примеров. Объемный набор экспериментов на задачах предобучения и классификации выявил наиболее эффективные метрики для использования в обучении по плану. В то же время было установлено, что обучение по плану негативно влияет на скорость сходимости на задаче предобучения, однако не уступает базовому подходу (обучению без плана) на задаче классификации. Также был рассмотрен важный частный случай обучения языковой модели на шумном наборе тренировочных данных. Сравнительный анализ показал ускорение обучения до двух раз для достижения 95% итоговой точности модели при применении обучения по плану с наиболее эффективной метрикой.

Ключевые слова: обработка естественного языка, обучение по плану, теория информации, оценка сложности текстовых данных

Modern state-of-the-art natural language processing systems use deep neural networks (BERT, GPT-3) that require many resources for training. Several techniques have been developed for the last ten years. One of them is curriculum learning, which consists of two parts, namely data complexity evaluation and sampling. The main purpose of this work is to research metrics of text complexity in the context of curriculum learning and explore the influence of curriculum learning on training time on pre-training and classification tasks. Several approaches from different mathematics fields were suggested and adapted during the research. Moreover, efficient algorithms for calculating given metrics on large datasets of several tens of millions of samples were implemented. Extensive experiments highlighted the most efficient metrics for use in curriculum learning. At the same time, it was established that curriculum learning negatively affects convergence time on pre-training task, but not inferior to the basic solution (learning without curriculum) on the classification task. Also, training on a noisy training dataset was considered. Comparative analysis showed a double reduction in training time needed to achieve 95% of final model accuracy using curriculum learning with the most effective metric.

Keywords: natural language processing, curriculum learning, information theory, text complexity estimation

Введение

На сегодняшний день существует множество сфер, где активно применяется обработка естественного языка. Например, в разработке голосовых помощников, алгоритмов фильтрации текста и машинного перевода. Возникающие задачи необходимо решать эффективно с точки зрения качества модели и скорости работы системы. За основу многих подходов взят механизм внимания [1]. На его базе были разработаны модели, такие как BERT [2], GPT-3 [10] и многие другие. Данные сети имеют высокое качество, однако, за это приходится платить существенным временем обучения. В рамках данной работы исследуется влияние обучения по плану на примере тренировки модели BERT, так как она является одной из самых популярных моделей, имеет высокую точность и сравнительно небольшой размер для удобства постановки экспериментов. Также стоит отметить, что для обучения модели используют объемные корпуса данных, состоящие из нескольких десятков миллионов примеров, для которых нужны производительные алгоритмы их обработки.

Таблица 1: Количество примеров в тренировочных корпусах данных

Корпус данных	Размер
Wikipedia	3-600M
BooksCorpus	74M
Hyperpartisan News Detection	600k-2M
sentiment140	1.6M
IWSLT	200-230k
QQP	364k
MNLI	393k

Процесс тренировки модели состоит из двух основных частей. Первая заключается в предобучении сети на задаче Masked Language Modelling [2], которая состоит в восстановлении предложения после замены 15% случайных слов на пробелы. Предобучение занимает несколько недель исполнения кода на дорогостоящих графических процессорах. Второй этап представляет из себя задачу дообучения языковой модели, например на задачу классификации, и требует несколько дней даже на элементарных задачах, таких как определение спама или грубой речи [11]. Одним из методов ускорения обучения моделей является обучение по плану [4]. При его применении данные сортируются по сложности, а затем семплируются с помощью заранее определенного алгоритма, который учитывает порядок данных. Данный подход хорошо себя показал во многих областях машинного обучения [6, 7, 12], однако в обработке естественного языка существует лишь ограниченное число успешных работ [3, 5]. Более того, на данный момент нет исследований влияния обучения по плану на скорость сходимости модели на задачах предобучения и классификации. Также в существующих работах

авторы уделяют большое внимание алгоритмам семплирования данных, а метрики берут из достаточного узкого множества, которое можно значительно расширить, применив различные сферы компьютерных наук. Это позволяет обозначить широкое поле для исследований подходов к оценке сложности текстов и предположить, что существует метрика, которая позволит значительно ускорить обучение модели на вышеуказанных задачах. Однако, в последнее время стали появляться работы с отрицательными результатами применения обучения по плану на задачах компьютерного зрения [14], что показывает спорную репутацию данного подхода к ускорению. В то же время, в тех же статьях авторы находят частные случаи применения обучения по плану на практике. Таким образом, можно выделить обширную сферу исследований нетривиального вопроса применимости обучения по плану к ускорению тренировочного процесса языковых моделей на задачах предобучения и классификации.

Цель и задачи

Целью данной работы является ускорение обучения языковой модели BERT с помощью обучения по плану за счет применения улучшенной метрики сложности текстовых данных на задачах классификации и предобучения

- Предложить метрики оценки сложности текста
- Реализовать производительные алгоритмы вычисления предложенных метрик на больших корпусах данных
- Сравнить найденные метрики
- Исследовать влияние найденных метрик на скорость обучения языковой модели BERT на чистых и шумных тренировочных данных

Достигнутые результаты

(ДОБАВИТЬ ОПИСАНИЕ РЕЗУЛЬТАТОВ)

Структура работы

(ДОБАВИТЬ СТРУКТУРУ РАБОТЫ)

1. Обзор литературы

1.1. Возникновение обучения по плану

Точная дата возникновения обучения по плану не известна, но можно выделить логическое начало в работе Bengio 2009 года [4], в которой было показано, что обучение по плану может привести к улучшению качества моделей машинного обучения. Авторы поставили несколько экспериментов, одним из которых является опыт по обучению классификатора геометрических фигур. Было обнаружено, что если сначала предъявить модели более простые примеры (квадраты, круги, равнобедренные треугольники) перед стандартным алгоритмом обучения, то итоговое качество возрастет. Этот простой пример подчеркивает большой потенциал обучения по плану к улучшению существующих алгоритмов в машинном обучении.

1.2. Применение обучения по плану в смежных сферах машинного обучения

Обучение по плану активно применялось в разных областях машинного обучения в течение последних нескольких лет. Например, Hacohe и Weinshall в 2019 году [7] применили данный метод к задачам компьютерного зрения. Они предложили модельную метрику оценки сложности картинок, которая считается следующим образом. Рассматривается независимая модель, предобученная на датасете ImageNet. Далее сложность примера определяется как уверенность модели в своем предсказании. Наконец, ученые использовали лестничный алгоритм семплирования в паре с предложенной метрикой. В результате был получен прирост в скорости обучения и в качестве итоговой модели.

Обучение по плану применяется и в классическом глубоком обучении. Merger и др. [12] предложили способ автоматической оценки сложности векторных данных для решения задачи классификации. Для этого авторы для каждого примера строят распределение вероятностей классов двумя способами.

1. на базе k ближайших соседей. Рассмотрим мультимножество меток соседей, тогда вероятность i -го класса равна доле соседей с данной меткой
2. на базе ансамбля. Обучим k независимых классификаторов стандартным алгоритмом. Далее для каждой метки определим среднюю предсказанную классификаторами вероятность того, что данный пример имеет рассматриваемую метку

В итоге сложность примера вычисляется как энтропия построенного распределения. Авторы рассмотрели 36 датасетов, на многих из которых обучение по плану выиграло у стандартного алгоритма обучения. Заметим, что подход, основанный на метках соседей, невозможно применить к текстам в явном виде, так как примеры из естественного языка не имеют векторной структуры. Однако можно рассмотреть пространство эмбедингов. Но данный способ будет зависеть от метода получения векторного представления текстов. Более того, размеры датасетов обучения языковых моделей состоят из большого числа примеров, и поиск k ближайших соседей может требовать большого количества времени, что недопустимо при решении задачи ускорения обучения. Те же самые проблемы возникают и при применении подхода, основанного на ансамблировании.

Важно отметить, что при применении обучения по плану можно получить и отрицательный результат. Так Wu и др. [14] выявили негативное влияние обучения по плану на скорость обучения широкого множества глубоких нейронных сетей на задаче классификации картинок. Авторы применили данный подход к более чем сотне архитектур, среди которых ResNet и VGG-19. Авторы рассмотрели несколько метрик сложности данных, которые сильно коррелировали с величиной $s(x_i, y_i)$ последней эпохи t , после которой модель w правильно отвечает на пример (x_i, y_i) вплоть до последней эпохи T (предсказание модели $\hat{y}_w(t)$ совпадает с реальной меткой y_i примера), для которого считается сложность (формула (1)).

$$s(x_i, y_i) = \min_{t^*} \{ \hat{y}_w(t)_i = y_i, \forall t^* \leq t \leq T \} \quad (1)$$

Было использовано семейство "префиксных" семплеров (рис. 1), а именно возрастающих функций, которые определяют долю легких примеров $g(t)$ в конкретный момент обучения t . Таким образом, данные семплеры в момент времени t строят батч данных, равновероятно выбирая примеры из первых $g(t)$ семплов отсортированного по метрике сложности датасета. В результате, ученые показали, что использование данной конфигурации обучения по плану не приводит ни к улучшению качества итоговой модели, ни к ускорению обучения. Также было рассмотрено два важных частных случая, а именно обучение на шумных данных и обучение с ограниченным числом тренировочных шагов. При добавлении 20% шума в тренировочный корпус, обучение по плану позволяет улучшить точность модели на 10%. Влияние же подхода на скорость обучения исследовано не было.

1.3. Применение обучения по плану в обработке естественного языка

В обработке естественного языка существует ограниченное число существенных




Рис. 1: Семейство функций для семплирования данных

результатов в контексте применения обучения по плану. Вероятно, это связано с тем, что естественный язык состоит из слов и предложений, не имеющих строгую структуру, которую сложно формально описать. Более того, на данный момент наука не понимает всех процессов, происходящих внутри современных языковых моделей.

Platanios и др. [3] исследовали влияние обучения по плану на задаче машинного перевода на скорость сходимости нейронных сетей. Авторы рассмотрели две метрики сложности текстов: длину и вероятность правдоподобия, которая вычисляется по формуле (2), где s_i — текст или набор токенов, w_k^i — слово или токен, $p(x)$ — доля токенов x во всем датасете.

$$d(s_i) = - \sum_{k=1}^N \log p(w_k^i) \quad (2)$$

Они показали, что правдоподобие не имеет никаких преимуществ по сравнению с длиной с точки зрения скорости обучения моделей. В качестве семплеров был взят префиксный семплер с функцией $c(t)$ (формула (3)), вычисляющий долю простых примеров, доступных для построения батча.

$$c(t) = \min \left(1, \sqrt{t \frac{1 - c_0^2}{T} + c_0^2} \right) \quad (3)$$

T — общее число тренировочных шагов, c_0 — доля простых примеров, доступных в самом начале обучения (авторы используют $c_0 = 0.01$)

В итоге, ученые добились улучшения качества модели на 2.2 BLEU и ускорения обучения на 70%.

Ху и др. [5] предложили альтернативный способ применения обучения по плану в обработке естественного языка на задаче Natural Language Understanding. Их метод оперирует понятием модельной оценки сложности текстов. Сложность примеров меняется в процессе обучения в зависимости от качества модели на момент применения метрики к примеру. Авторы предлагают алгоритм, который в цикле повторяет следующую процедуру. Тренировочный корпус данных разделяется на несколько частей. Затем, для каждого блока независимо обучается новая модель, которая инициализируется весами текущей глобальной модели. После этого оценивается сложность всех

примеров как сумма уверенностей всех моделей по всем блокам кроме блока, в котором находится данный пример (рис. 2).




Рис. 2: Алгоритм вычисления модельной метрики сложности текста. На данной схеме датасет делится на 4 части, на каждой из которых учится независимая модель BERT с начальными весами текущей глобальной модели. Сложность примеров в блоке под номером 3 вычисляется как сумма уверенностей моделей W_1, W_2, W_4 .

Наконец, весь датасет сортируется в соответствии с найденными сложностями примеров, и текущая глобальная модель обучается на новой эпохе, обрабатывая примеры в порядке возрастания сложности. Данный подход позволяет улучшить точность итоговой модели на 1.5%, но требует существенно больше времени.

В 2017 году Космі и др. [8] провели сравнительный анализ двух подходов к ускорению обучения: minibatch bucketing и обучение по плану. Первый подход отличается от стандартного алгоритма обучения нейронных сетей только построением батчей, каждый из которых содержит данные, слабо отличающиеся по заранее определенному показателю (например, батч из предложений с не более чем пятью глаголами). Для обучения по плану авторы используют три метрики.

1. длина предложения
2. максимальный частотный ранг слова – для каждого слова вычисляется количество его вхождений в тренировочный корпус данных. Затем все слова сортируются в порядке убываения частоты. Рангом слова называется его позиция в данном отсортированном массиве. Сложность предложения определяется как максимальный ранг по всем словами в данном предложении
3. количество конъюнкций (например, эту метрику можно определить как количество союзов)

Исследование показало, что обучение по плану позволяет увеличить качество итоговой модели на 1 BLEU, но без уменьшения времени обучения. Более того, модель, обучаемая с помощью обучения по плану достигает 85%-го качества модели, обученной базовым алгоритмом, в два раза медленнее.

Важный вклад в исследование обучения по плану внесли Zhang и др. [15] в 2018 году. В качестве метрик оценки сложности текста авторы рассматривают модельную метрику, длину, максимальный частотный ранг и средний частотный ранг. В данной работе ранг слова определяется аналогично работе Космі и др. [8]. Модельная метрика определяется ошибкой вспомогательной модели, заранее обученной на задачу машинного перевода стандартным алгоритмом. Принципиальным отличием данной работы является выбор методов построения батчей. Ученые не рассматривают префиксные семплы, а используют алгоритмы, с течением времени изменяющие распределение вероятности взять пример в текущий батч. Авторы показали, что обучение по плану очень чувствительно к выбору гиперпараметров. Среди нескольких десятков конфигураций лишь некоторые позволяют получить ускорение обучения модели до 30% без потери точности. Также было установлено, что длина не является удачной метрикой для обучения по плану, а именно она приводит к замедлению обучения модели до двух раз и уменьшению точности модели до 4.2 BLEU.

1.4. Существующие метрики оценки сложности текстов

Таким образом, был рассмотрен ряд метрик, активно используемых в обучении по плану: длина [3, 8, 15], вероятность правдоподобия [3], модельная [5], максимальный [8, 15] и средний [15] частотный ранг.

На первый взгляд кажется, что можно придумать еще несчетное количество подходов. Действительно, существует большое количество метрик оценки сложности текстов. Это показал Kurdi в своей статье 2020 года [9], в которой решал задачу определения уровня английского языка, необходимого для прочтения текста. Для этого он строил множество признаков входного текста для их передачи на вход классификатору. Ученый рассмотрел несколько десятков методов определения сложности текста понятных для человека: фонологические, морфологические, лексические, синтаксические признаки и многие другие. Это позволило решить задачу с высокой точностью. Несмотря на хорошее качество полученной модели, вопрос применимости данных метрик к обучению по плану остается открытым. Однако на него можно найти ответ в работе Frans van der Sluis и Egon L. van den Broek [17]. Они рассмотрели два набора данных, Wikipedia и Simple English Wikipedia (упрощенная версия Wikipedia, состоит из статей меньшей длины, написанных более простым языком), и показали что лингвистические метрики плохо коррелируют с реальной сложностью текстов. Таким образом, классические методы оценки сложности текстовых данных имеют меньший приоритет для рассмотрения в сравнении с метриками, основанными на статистических подходах.

Оценка сложности текстов тесно связана с количеством информации в них. Этот

объект изучает теория информации. В 2006 году Ау и др. [16] предложили четыре метода оценки сложности конечных дискретных систем. К сожалению, в чистом виде данные подходы невозможно применить к текстам, так как они (подходы) получают на вход некоторую совместно распределенную случайную величину. Однако эти метрики можно адаптировать, о чем будет рассказано в последующих главах.

1.5. Выводы

- Нет существующих исследований влияния обучения по плану на скорость сходимости на не менее важных задачах предобучения языковых моделей и классификации текстов
- Рассмотрено узкое множество метрик оценки сложности текстов, которое можно расширить, используя методы из смежных областей математики и информатики, таких как теория информации и информационный поиск
- Большинство работ применяют обучение по плану для улучшения качества модели, но не скорости ее обучения
- Можно заметить, что во многих работах обучение по плану приводит к уменьшению тренировочного времени и увеличению точности моделей только в определенных конфигурациях, которые сильно зависят от гиперпараметров, задачи, модели и корпуса данных. Важной деталью является тот факт, что все эксперименты были проведены на чистых наборах данных. Такая ситуация редко встречается при решении прикладных задач и реализации реальных проектов. Например, крупные компании тратят большие деньги для очистки тренировочных данных. Таким образом, важность исследования обучения языковых моделей на шумных корпусах данных очевидна, однако работ, освещающих данный вопрос найдено не было

2. Метрики оценки сложности текстов

В этой главе будут предложены метрики оценки сложности текстов и представлены производительные алгоритмы для их вычисления на больших корпусах данных из нескольких десятков миллионов примеров.

2.1. Описание метрик

Одним из недостатков существующих работ является узкое множество рассматриваемых метрик. Чтобы решить эту проблему необходимо предложить ряд метрик, расширяющих это множество. В данной работе не рассматриваются лингвистические метрики, так как они плохо себя показали в существующих работах, рассмотренных в главе 1.

Во-первых, необходимо взять уже существующие методы оценки сложности текстов.

1. Длина текста
2. Вероятность правдоподобия (формула (2))
3. Максимальный частотный ранг

Во-вторых, в рамках данной работы я предлагаю взглянуть на задачу оценки сложности текстов с точек зрения информационного поиска, теории информации и обучаемой модели.

Информационный поиск занимается быстрым поиском документов в большой базе данных по входному запросу. В простом описании это делается посредством поиска ближайшего документа по некоторому расстоянию (например, косинусному). Чтобы считать дистанцию, нужно по документу получить некоторый вектор. Одним из наиболее популярных и простых способов это сделать является применение метрики TF-IDF (формула (4)).

$$TF_IDF(d, t) = TF(d, t) \cdot IDF(t, D) \quad (4)$$

$$TF(d, t) = \frac{n_t}{\sum_j n_j} \quad (5)$$

$$IDF(t, D) = \frac{|D|}{|\{d \in D: t \in d\}|} \quad (6)$$

Здесь D – коллекция документов, d – конкретный документ из коллекции, t – конкретный токен (слово в предложении) в документе, n_t – количество вхождений

токена t в документ. Таким образом TF_IDF – это произведение TF и IDF , где TF – вероятность вхождения токена в документ, а IDF – это величина, обратная доле документов, в которых встречается данный токен. Эта метрика максимизируется, когда частый токен в конкретном документе встречается в малой доле всех документов, следовательно она выделяет наиболее важные токены в документе. Заметим, что TF_IDF позволяет получить по тексту некоторый вектор, а мы хотим получить некоторое число. Давайте рассмотрим сумму TF_IDF по всем словам в предложении. Таким образом, мы определяем потенциал предложения как сумму важностей входящих в него слов.

Теория информации позволяет понять, сколько информации находится в том или ином объекте. Давайте рассмотрим универсальный фреймворк для измерения сложности конечных систем, предложенный Ау и др. [16]. Авторы заметили, что количество информации в дискретных последовательностях не является простой суммой количества информации в отдельных ее частях, и предложили четыре подхода, основанных на декомпозиции системы на подсистемы в контексте их иерархического взаимодействия. В чистом виде данные методы нельзя применить к текстам, так как они оперируют понятием совместно распределенной случайной величины. Возьмем две метрики, одновременно содержательных и удобных для адаптации к задаче обработки естественного языка, а именно TSE (формула (7)) и Excess Entropy (EE, формула (8)).

$$TSE(X_V) = \sum_{k=1}^{n-1} \frac{k}{n} C^{(k)}(X_V) \quad (7)$$

$$C^{(k)}(X_V) = \frac{n}{k \binom{n}{k}} \sum_{A \subseteq V, |A|=k} H(X_A) - H(X_V)$$

$$EE(X_V) = \left[\sum_{v \in V} H(X_{V \setminus \{v\}}) \right] - (n-1)H(X_V) \quad (8)$$

Здесь $X_V = (X_1, X_2, \dots, X_n)$, $V = \{1, 2, \dots, n\}$, $A = \{i_1, i_2, \dots, i_k\}$, $X_A = (X_{i_1}, X_{i_2}, \dots, X_{i_k})$, H – энтропия, n – длина вектора X .

Теперь необходимо научиться их использовать, а именно по тексту $T = (t_1, t_2, \dots, t_n)$ построить некоторую совместно распределенную случайную величину (вектор вещественнозначных случайных величин) ξ . Определим $\mu_i := \xi_{t_i}^i$ как бинарную (принимающую значения из $\{0, 1\}$) случайную величину, зависящую от значения слова t_i в тексте и его позиции i . Пусть $P(\xi_{t_i}^i = 1) = \frac{\text{число текстов, у которых на } i\text{-й позиции стоит слово } t_i}{\text{общее число текстов длины хотя бы } i}$. Тогда $\xi = (\xi_{t_1}^1, \xi_{t_2}^2, \dots, \xi_{t_i}^i, \dots, \xi_{t_n}^n)$. Такая адаптация позволяет использовать теоретико-информационные метрики, сохраняет структуру предложения и учитывает статистические особенности конкретного примера относительно всего датасета.

Теперь рассмотрим подход, который будет опираться на показания обучаемой модели. Пусть мы тренируем модель M_1 типа T (например, BERT). Возьмем модель M_2 того же типа, заранее предобученную на задачу Masked Language Modelling (MLM). В процессе предобучения оптимизируется кросс энтропия. Определим сложность примера T_i как значение данной функции потерь модели на данном примере (формула 9)

$$MLM_loss(T_i) = CrossEntropy(T_i, M_2(T_i)) \quad (9)$$

Здесь $M_2(T_i)$ – предсказание модели M_2 после замены 15% случайных слов в T_i на пробелы.

Заметим, что такой подход опирается на структуру конкретной модели и позволяет косвенно определить, насколько конкретный пример сложен для рассматриваемой модели. Данная метрика мотивирована существующими аналогами из рассмотренных в главе 1 работ.

Одно из направлений исследований, представленных в данной работе, а именно обучение на шумных тренировочных данных, позволило выявить метрику, которая дает положительные результаты в контексте применения обучения по плану. Рассмотрим величину, равную среднему числу токенов на слово. Более формально этот подход описывается следующим образом.

- На вход рассматриваемой в данной работе модели BERT подается последовательность токенов, полученная применением токенизатора к входному тексту
- Таким образом, мы знаем количество слов в тексте w и число токенов t в полученной последовательности токенов
- Определим среднее число токенов на слово как $TPW = \frac{t}{w}$ (tokens per word)

Данный подход возник после проведения экспериментов, заключающихся в обучении модели на шумном наборе данных (тексты с опечатками), и наблюдении за данными, которые подаются на вход модели. Выяснилось, что шумный текст токенизируется большим числом токенов, так как словарь токенизатора состоит в основном из наиболее частых слов в языке. Шумный же набор данных состоит из слов со множеством опечаток, что не позволяет обойтись малым числом токенов на слово. Таким образом данная метрика позволяет отсортировать данные в порядке зашумленности. Другими словами в начале обучения модель будет учиться на чистых примерах, постепенно переходя к предложениям с большим числом опечаток, что приводит к более стабильному обучению.

(ДОБАВИТЬ ПРИМЕР С ТОКЕНИЗАЦИЕЙ ШУМНЫХ ТЕКСТОВ)

2.2. Алгоритмы вычисления метрик

Перейдем к описанию алгоритмов вычисления предложенных метрик. Обратимся к таблице 2.

Таблица 2: Время работы алгоритмов вычисления метрик по определению на датасете Hyperpartisan News Detection из 2М примеров длины от 50 до 200

Метрика	Асимптотика	Реальное время работы
Длина	$\mathcal{O}(n)$	< 30 мин.
Вероятность правдоподобия	$\mathcal{O}(n)$	< 5 ч.
Максимальный частотный ранг	$\mathcal{O}(n)$	< 5 ч.
TF-IDF	$\mathcal{O}(n)$	< 5 ч.
TSE	$\mathcal{O}^*(2^n)$	∞
EE	$\mathcal{O}(n^2)$	> 1 мес.
TPW	$\mathcal{O}(n)$	< 5 ч.

Видно, что большинство метрик не нуждаются в разработке производительного алгоритма для их вычисления. Однако, для TSE и EE это сделать придется.

Сначала разберем алгоритм вычисления энтропии у вектора большой длины. Распишем энтропию как сумму условных энтропий. Также предположим, что достаточно далекие друг от друга случайные величины независимы. Получим формулу 10.

$$H(\mu) = \sum_{i=1}^n H(\mu_i | \mu_1, \mu_2, \dots, \mu_{i-1}) = \sum_{i=1}^n H(\mu_i | \mu_{i-L}, \dots, \mu_{i-1}) \quad (10)$$

Здесь L – это длина контекста, от которого будет зависеть случайная величина i . Заметим, что при выборе достаточно большого контекста энтропия вырождается в длину, так как можно считать, что все подтексты длины L разные, следовательно вероятность того, что $\mu_1 = x_1, \mu_2 = x_2, \dots, \mu_L = x_L$ одинакова для всех (x_1, \dots, x_L) , которые встречаются в датасете. Однако в процессе реализации вычисления энтропии выяснилось, что даже при $L = 2$ время работы существенно превышает итоговое время обучения модели. Таким образом, приходится ограничиваться случаем $L = 1$. В итоге получаем формулу (11) для вычисления энтропии, каждое слагаемое в котором вычисляется за $\mathcal{O}(1)$.

$$H(\mu) = H(\mu_1) + H(\mu_2 | \mu_1) + \dots + H(\mu_i | \mu_{i-1}) + \dots + H(\mu_n | \mu_{n-1}) \quad (11)$$

Разберем алгоритм вычисления метрики EE. Заметим, что EE представляет из себя разность двух величин (формула (8)), последняя из которых вычисляется за $\mathcal{O}(n)$. Необходимо оптимизировать вычисление первой величины $\sum_{v \in V} H(X_{V \setminus \{v\}})$. Раскроем $H(X_{V \setminus \{v\}})$ по формуле (11), подставим это выражение в определение EE (формула

(8)) и получим упрощенную версию формулы для EE, вычисляемую за $\mathcal{O}(n)$ (формула (12)).

$$\begin{aligned} \sum_{i=1}^n H(\mu_1, \dots, \mu_{i-1}, \mu_{i+1}, \dots, \mu_n) &= \sum_{i=1}^n H(\mu) - H(\mu_i | \mu_{i-1}) - H(\mu_{i+1} | \mu_i) + H(\mu_{i+1}) \\ EE(X) &= \sum_{i=2}^n H(\mu_i) - H(\mu_i | \mu_{i-1}) = \sum_{i=2}^n I(\mu_{i-1} : \mu_i) \end{aligned} \quad (12)$$

Наконец, разберем алгоритм вычисления TSE. Данную метрику можно вычислить за экспоненциальное время, но для этого нужны огромные ресурсы. Первый разработанный мною алгоритм, вычисляющий TSE, работал за $\mathcal{O}(n^2)$. Он основывался на технике динамического программирования, однако он сложен для понимания и все еще требовал большого количества ресурсов. Однако позже был придуман алгоритм, работающий за $\mathcal{O}(n)$ и использующий разумное количество процессорного времени. Давайте опишем его в деталях.

Пусть $S_1 = \sum_{i=1}^n H(\mu_i)$, $S_2 = \sum_{i=2}^n H(\mu_i | \mu_{i-1})$, $h = H(X_V)$. Заметим, что S_1, S_2, h вычисляются за $\mathcal{O}(n)$. Пусть $E = \frac{1}{\binom{n}{k}} \sum_{A \subseteq V, |A|=k} H(\mu_A)$. Тогда $C^{(k)}(\mu_V) = \frac{n}{k} E - h$. Заметим, что E – математическое ожидание энтропии случайного подмножества случайных величин из множества $\{\mu_1, \dots, \mu_n\}$. Воспользуемся линейностью математического ожидания и получим формулу (13).

$$E = \sum_{i=1}^n A_i H(\mu_i) + \sum_{i=2}^n B_i H(\mu_i | \mu_{i-1}) \quad (13)$$

Заметим, что A_i – вероятность того, что в случайном подмножестве будет μ_i , но не будет μ_{i-1} . Тогда A_i вычисляются по формуле (14).

$$A_i = \begin{cases} \binom{n-2}{k-1} / \binom{n}{k} = \frac{k(n-k)}{n(n-1)}, & i > 1 \\ \binom{n-1}{k-1} / \binom{n}{k} = \frac{k}{n}, & i = 1 \end{cases} \quad (14)$$

Аналогично, B_i – вероятность того, что и μ_i , и μ_{i-1} будут в случайном подмножестве. Тогда B_i вычисляются по формуле (15).

$$B_i = \frac{\binom{n-2}{k-2}}{\binom{n}{k}} = \frac{k(k-1)}{n(n-1)} \quad (15)$$

Заметим, что $\forall i > 2$ верно $A_i = A_2$ и $\forall i$ верно $B_i = B_2$. Тогда верна формула (16).

$$E = A_1 H(\mu_1) + A_2 (S_1 - H(\mu_1)) + B_2 S_2 \quad (16)$$

Таким образом, итоговый алгоритм вычисляет TSE за линейное время и требует пренебрежимо маленькое количество времени по сравнению со всем временем обуче-

ния модели.

2.3. Сбор статистик

Для вычисления большинства метрик требуются дополнительные статистики, собираемые со всего датасета.

- длина \rightarrow число текстов с такой длиной
- $(i, x_i) \rightarrow$ число текстов, где $t_i = x_i$
- $(x_i) \rightarrow$ число текстов, где x_i является последним токеном
- $(i, x_{i-1}, x_i) \rightarrow$ число текстов, где на $(i-1)$ -й позиции стоит x_{i-1} , а на i -й позиции стоит x_i
- $x_i \rightarrow$ число текстов, в которых есть x_i
- $x_i \rightarrow$ число вхождений x_i в весь датасет

На больших датасетах тривиальный алгоритм сбора таких статистик может занимать большое количество времени, так как при росте размера корпуса данных количество ключей в хранилище также возрастает, что приводит к замедлению системы. Поэтому был предложен альтернативный подход. Заметим, что все статистики не требуют информации о двух предложениях в один момент времени. Тогда можно поделить весь датасет на несколько блоков, собрать статистики на каждом из них, а после слить в одно хранилище. Этот способ ускоряет подсчет статистик в несколько десятков раз, так как количество ключей при подсчете одного блока небольшое, следовательно и сбор данных из одного куска, и слияние всех статистик в одно место требуют значительно меньше ресурсов.

Таблица 3: Время работы алгоритмов сбора статистик на датасете Hyperpartisan News Detection из 2М примеров длины от 50 до 200

Режим	Реальное время работы
1 CPU	≈ 2 недели
5 CPU	$\approx 1-2$ дня
20 CPU	< 14 ч.
40 CPU	< 6 ч.

Таким образом, при делении корпуса данных примерно на 20 равных частей можно собрать все необходимые статистики за разумное время.

2.4. Выводы

В этой главе мною был предложен ряд метрик оценки сложности текстов из разных областей математики и информатики: длина, вероятность правдоподобия, максимальный ранг слова, TF-IDF, EE, TSE, TPW. Метрики EE и TSE были адаптированы под задачу обработки естественного языка. Для всех метрик был описан линейный алгоритм их вычисления, требующий пренебрежимо маленькое количество временных ресурсов относительно общего времени обучения. Также был представлен производительный алгоритм сбора статистик, необходимых для вычисления предложенных метрик на больших объемах данных.

3. Эксперименты

Описать, что будет происходить в главе (после написания самой главы)

3.1. Конфигурация экспериментов

В рамках данной работы произведены эксперименты на задаче предобучения и классификации. Для их реализации выбраны следующие датасеты.

- BooksCorpus – корпус данных, содержащий отрывки текстов из большого числа книг разных жанров. Он состоит из 74М примеров и 800М слов. Его использовали для обучения модели BERT в оригинальной статье [2]
- Hyperpartisan News Detection – датасет, соответствующий задаче №4 международного семинара по семантической оценке SemEval-2019, которая формулируется следующим образом. Дан текст новостной статьи. Нужно определить, является ли он необоснованно предвзятым или склонным по отношению к той или иной партии, фракции или политическому деятелю. Этот набор данных содержит 600k примеров статей. Стандартным алгоритмом его обработки является деление примеров на несколько коротких примеров длины от 50 до 200, где каждой части проставляется метка всей статьи. Аналогичным образом сделано в этой работе. Таким образом, данный датасет состоит из 2М примеров длины от 50 до 200
- sentiment140 – размеченный датасет, состоящий из 1.6М твитов (сообщений в социальной сети Twitter). Каждому примеру соответствует метка, описывающая эмоциональный окрас текста (негативный или позитивный)

Для экспериментов на задаче предобучения будет использоваться датасет BooksCorpus, а на задаче классификации – датасеты Hyperpartisan News Detection (HND) и sentiment140 (s140).

В качестве языковой модели используется BERT-base (110М параметров). Гиперпараметры обучения установлены в стандартные значения, описанные в оригинальной статье [2]. Также был использован стандартный токенизатор WordPiece.

3.2. Метод сравнения метрик

Перед тем как производить эксперименты нужно понять, как сравнивать два подхода между собой. Допустим, нужно сравнить две метрики f_1 и f_2 между собой. Для этого используется следующая процедура.

1. Фиксируем все кроме двух метрик
2. Обучаем две модели M_1 и M_2 с помощью обучения по плану (используем метрику f_1 для обучения M_1 и f_2 для обучения M_2). На выходе получаем два графика зависимости точности (или функции потерь) от числа тренировочных шагов
3. Фиксируем достаточно большой порог точности α (или достаточно низкий порог значения функции потерь)
4. Вычисляем среднее (по нескольким запускам с разными случайными инициализациями) количество тренировочных шагов, необходимое для достижения данного порога. На выходе получаем две пары (a_1, Δ_1) и (a_2, Δ_2) , где a_i – среднее число шагов, а Δ_i – стандартное отклонение
5. Сравниваем a_1 и a_2 . Тот метод, который требует меньшее число шагов ($a_i \rightarrow \min$) и является лучшим (рис. 3). В этом случае будет говорить, что одна метрика быстрее другой.




Рис. 3: Среднее число шагов, необходимое для достижения порога $\alpha = 0.85$, $a_1 = 10k$, $a_2 = 20k$. Метод, соответствующий оранжевому графику, является лучшим.

3.3. Семплы

(ОПИСАТЬ СЕМПЛЕРЫ)

3.4. Влияние обучения по плану на задаче предобучения




Рис. 4: Графики зависимости функции потерь от числа шагов обучения на задаче предобучения на датасете BooksCorpus на первых 15% обучения

Для исследования влияния обучения по плану на скорость обучения языковых моделей на задаче предобучения были проведены эксперименты с использованием всех конфигураций семплер-метрика за исключением метрики `MLM_loss`, так как ее применение неразумно из-за того, что итоговое время обучения возрастет как минимум в два раза: для вычисления метрики `MLM_loss` нужна предобученная модель, а в рамках данной группы экспериментов такими моделями мы не располагаем. В итоге было получено 7×5 графиков, которые можно наблюдать на рис. 4. Можно заметить, что при использовании 4/5 семплеров метрики образуют строгий порядок, а именно: максимальный ранг слова, TF-IDF, EE, TSE, вероятность правдоподобия и длина. На этих графиках виден сильный проигрыш обучения по плану по сравнению со стан-

Таблица 4: Среднее число шагов всех конфигураций метрика-сэмплер на задаче предобучения на датасете BooksCorpus, необходимое для достижения порога. Максимальное стандартное отклонение $\Delta \leq 3k$

Корпус данных		BooksCorpus					
сэмплер	Порог	CB	DB	Hyp	SS	SM	min loss
max wf rk	2.00	∞	17.5k	16.5k	16.5k	27k	1.58
TF-IDF	2.00	∞	34k	35k	37.5k	∞	1.84
база	2.00	9.5k					1.58
		BooksCorpus					
EE	3.50	∞	4k	3.5k	4.5k	9.5k	2.25
TSE	3.50	∞	9k	9k	8.5k	18k	2.60
правдоподобие	3.50	∞	13.5k	13.5k	15.5k	50k	2.83
длина	3.50	∞	50.5k	∞	-	-	3.45

дартным алгоритмом обучения языковых моделей. Чтобы точнее определить разницу обратимся к таблице 4. Во-первых, метрики разделены на две группы. Первая группа состоит из максимального ранга слова, TF-IDF. Вторая группа состоит из EE, TSE, вероятности правдоподобия и длины. Это связано с тем, что в первой группе метрики сходятся к гораздо более низким значениям по сравнению с метриками из второй группы. Следовательно тяжело выбрать такой порог, на котором можно было бы различать метрики внутри каждой группы. Таким образом можно сказать, что метрики из первой группы быстрее метрик из второй группы. Заметим, что в первой группе максимальный ранг слова позволяет получить такое же качество итоговой модели, как у базового подхода. В то время как остальные подходы такой возможности не предоставляют. К сожалению, приходится констатировать тот факт, что обучение по плану не ускоряет обучение моделей на задаче предобучения. Более того, применение обучения по плану приводит к замедлению от 2 до 5 раз.

3.5. Влияние обучения по плану на задаче классификации

Таблица 5: Среднее число шагов всех конфигураций метрика-семплер на задаче классификации на датасете sentiment140, необходимое для достижения порога. Максимальное стандартное отклонение $\Delta \leq 3k$

Корпус данных		sentiment140					
семплер	Порог	CB	DB	Нур	SS	SM	Точность
длина	85.5%	112.5k	20k	19k	-	-	86.2%
TF-IDF	85.5%	115.5k	21.5k	19.5k	16.5k	22k	86.7%
TSE	85.5%	95.5k	16.5k	20.5k	21.5k	18k	86.8%
EE	85.5%	59k	19.3k	23k	20k	19k	86.7%
max wf rk	85.5%	70k	18.5k	19.5k	17k	19k	86.7%
правдоподобие	85.5%	112k	17.5k	21.5k	17.5k	21.5k	86.7%
MLM-loss	85.5%	59.5k	21k	23.5k	19.5k	20k	86.1%
база	85.5%	17.5k					87%

Таблица 6: Среднее число шагов всех конфигураций метрика-семплер на задаче классификации на датасете Hyperpartisan News Detection, необходимое для достижения порога. Максимальное стандартное отклонение $\Delta \leq 3k$

Корпус данных		HND					
семплер	Порог	CB	DB	Нур	SS	SM	Точность
длина	92.9%	55k	23k	22.5k	-	-	93.7%
TF-IDF	92.9%	∞	19.5k	24k	23.5k	33k	93.5%
TSE	92.9%	56.5k	21k	23k	22k	31k	93.8%
EE	92.9%	71.5k	25.5k	22.5k	19.5k	32.5k	93.8%
max wf rk	92.9%	∞	22k	20.5k	22.5k	39k	93.6%
правдоподобие	92.9%	∞	20k	24k	20k	30k	93.8%
база	92.9%	22k					93.8%

(ДОБАВИТЬ MLM_loss + HND)

Перейдем к описанию результатов применения обучения по плану на задаче классификации. Здесь были произведены эксперименты со всеми метриками на двух корпусах данных: sentiment140 и Hyperpartisan News Detection. Обратимся к таблицам 5 и 6. Во-первых, заметим, что на датасете sentiment140 при использовании обучения по плану проседает итоговая точность модели на 0.3% для всех метрик кроме длины и MLM_loss (на них просадка в 0.8% и 0.9% соответственно), в то время как на датасете Hyperpartisan News Detection этого не происходит. Возможная причина заключается в том, что sentiment140 содержит тексты меньшей длины, следовательно для выразительной модели BERT сложность примеров почти неразличима. Однако, это утверждение ложно до определенного момента. Если выбрать высокий порог точности в 85.5% (-1.5% итоговой точности), то разница в метриках существенна, а именно метрики TF-IDF, TSE и максимальный ранг слова приводят к хоть и не значительному,

но ускорению обучения на 3%. Остальные метрики замедляют скорость сходимости модели. Также заметим, что при увеличении размера датасета (`sentiment140` → `HND`) в множество ускоряющих метрик $\{\text{TF-IDF}, \text{max-wf rk}, \text{TSE}\}$ добавляются остальные. Это соотносится с экспериментами на задаче предобучения. Там наиболее быстрыми метриками являлись максимальный ранг слова и TSE. Длина же ни в одной конфигурации не позволяет ускорить обучение модели, что подтверждает гипотезу о том, что данная метрика не является разумным выбором метода оценки сложности текстов в контексте обучения по плану. Еще один важный вывод заключается в том, что модель не всегда может выдать правильную характеристику примеру относительно его сложности (`MLM_loss` не ускоряет обучение модели и ухудшает итоговое качество на датасете `sentiment140`)).

3.6. Влияние обучения по плану на шумном корпусе данных

Важным случаем в машинном обучении является ситуация, когда приходится обучать модели на шумных наборах данных. Такое может встречаться у компаний, которые автоматически собирают данные. Например, можно построить корпус данных, основываясь на открытых сообщениях некоторого форума. Очевидно, люди при использовании подобных сервисов не уделяют должного внимания грамотности и пунктуации написанных сообщений. Для их очистки требуются существенные денежные ресурсы. Поэтому важной задачей является быстрое и качественное обучение моделей в подобных окружениях. В данном блоке экспериментов будет исследовано влияние обучения по плану на скорость сходимости языковой модели BERT при ее обучении на шумном наборе данных.

Для эмуляции описанной выше ситуации мы искусственно добавим шум в корпус данных. В работе [13], в которой исследуется влияние шума на языковую модель BERT, авторы предложили так называемый клавиатурный шум. Чтобы его применить к тексту, нужно взять какую-то долю символов и заменить их на случайного соседа на стандартной QWERTY клавиатуре. Помимо этого шума в данной работе предложено рассмотреть еще два вида шумов: случайные вставки и случайные удаления. Алгоритм зашумления текстовых данных выглядит следующим образом.

1. Выбираем случайное число $\rho \sim U[0, \rho_{max}]$
2. Применяем шум с долей испорченных символов равной ρ

В данной группе экспериментов будет добавлена метрика TPW (среднее число токенов на слово).

(ДОБАВИТЬ ТАБЛИЦУ СО ВСЕМИ МЕТРИКАМИ+СЕМПЛЕРАМИ+ВСЕ ВИДЫ ШУМА)



Рис. 5: Графики зависимости точности от числа шагов обучения на задаче классификации на датасете sentiment140 на первых 10% обучения при добавлении клавиатурного шума

3.7. Выводы

сделать выводы по главе

Заключение

сделать выводы по всей работе, достигнута ли цель? выполнены ли задачи? объяснить возможные причины отрицательного результата и описать реальные направления для дальнейших исследований

Список литературы

- [1] Attention is all you need / Ashish Vaswani, Noam Shazeer, Niki Parmar et al. // arXiv preprint arXiv:1706.03762. — 2017.
- [2] Bert: Pre-training of deep bidirectional transformers for language understanding / Jacob Devlin, Ming-Wei Chang, Kenton Lee, Kristina Toutanova // arXiv preprint arXiv:1810.04805. — 2018.
- [3] Competence-based curriculum learning for neural machine translation / Emmanouil Antonios Platanios, Otilia Stretcu, Graham Neubig et al. // arXiv preprint arXiv:1903.09848. — 2019.
- [4] Curriculum learning / Yoshua Bengio, Jérôme Louradour, Ronan Collobert, Jason Weston // Proceedings of the 26th annual international conference on machine learning. — 2009. — P. 41–48.
- [5] Curriculum learning for natural language understanding / Benfeng Xu, Licheng Zhang, Zhendong Mao et al. // Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. — 2020. — P. 6095–6104.
- [6] Curriculum learning for reinforcement learning domains: A framework and survey / Sanmit Narvekar, Bei Peng, Matteo Leonetti et al. // Journal of Machine Learning Research. — 2020. — Vol. 21, no. 181. — P. 1–50.
- [7] Hacohen Guy, Weinshall Daphna. On the power of curriculum learning in training deep networks // International Conference on Machine Learning / PMLR. — 2019. — P. 2535–2544.
- [8] Kocmi Tom, Bojar Ondrej. Curriculum learning and minibatch bucketing in neural machine translation // arXiv preprint arXiv:1707.09533. — 2017.
- [9] Kurdi M Zakaria. Text Complexity Classification Based on Linguistic Information: Application to Intelligent Tutoring of ESL // arXiv preprint arXiv:2001.01863. — 2020.
- [10] Language models are few-shot learners / Tom B Brown, Benjamin Mann, Nick Ryder et al. // arXiv preprint arXiv:2005.14165. — 2020.
- [11] MITRE at SemEval-2019 task 5: Transfer learning for multilingual hate speech detection / Abigail S Gertner, John Henderson, Elizabeth Merkhofer et al. // Proceedings of the 13th International Workshop on Semantic Evaluation. — 2019. — P. 453–459.

- [12] Mermer Melike Nur, Amasyali Mehmet Fatih. Scalable Curriculum Learning for Artificial Neural Networks // IPSI BGD TRANSACTIONS ON INTERNET RESEARCH. — 2017. — Vol. 13, no. 2.
- [13] Srivastava Ankit, Makhija Piyush, Gupta Anuj. Noisy Text Data: Achilles' Heel of BERT // Proceedings of the Sixth Workshop on Noisy User-generated Text (W-NUT 2020). — 2020. — P. 16–21.
- [14] Wu Xiaoxia, Dyer Ethan, Neyshabur Behnam. When Do Curricula Work? // arXiv preprint arXiv:2012.03107. — 2020.
- [15] An empirical exploration of curriculum learning for neural machine translation / Xuan Zhang, Gaurav Kumar, Huda Khayrallah et al. // arXiv preprint arXiv:1811.00739. — 2018.
- [16] A unifying framework for complexity measures of finite systems / Nihat Ay, Eckehard Olbrich, Nils Bertschinger, Jürgen Jost // Proceedings of ECCS / Citeseer. — Vol. 6. — 2006.
- [17] van der Sluis Frans, van den Broek Egon L. Using complexity measures in information retrieval // Proceedings of the third symposium on information interaction in context. — 2010. — P. 383–388.